Formulación de Procesos para una Ingeniería de Explotación de Información Espacial

Giovanni Daián Rottoli

[1] Programa de Doctorado en Ciencias Informáticas. Facultad de Informática. Universidad Nacional de La Plata. Argentina
[2] Grupo de Investigación de Sistemas de Información (GISI). Universidad Nacional de Lanús. Argentina
rottolig@frcu.utn.edu.ar

Abstract. ***Antecedentes:*** El Proceso de Descubrimiento de Conocimiento en Base de datos (KDD, *Knowledge Discovery in Databases*) propuesto por Fayyad et al. (1996) proporciona una secuencia unificada de pasos para la obtención de patrones de conocimiento mediante la aplicación de algoritmos de minería de datos a partir de un conjunto de datos de entrada. Posteriormente fue propuesta una batería de procesos de explotación de información que concretan parcialmente al proceso KDD permitiendo combinar distintas familias de algoritmos de minería de datos para la obtención de patrones de conocimiento relevantes para la inteligencia de negocio. ***Definición del Problema:*** El arribo de nuevas tecnologías para la obtención de datos referenciados espacialmente, permitió adquirir nuevos tipos de patrones útiles para la toma de decisiones estratégicas. Sin embargo, debido a las particularidades de este nuevo tipo de información y a las diferencias semánticas asociadas a las mismas, los procesos de explotación de información tradicionales no resultan útiles para este objetivo. ***Objetivo***. Se propone, entonces, un nuevo conjunto de procesos que combinen distintas técnicas de pre-procesamiento, minería, y pos-procesamiento de datos para satisfacer las necesidades de la inteligencia de negocio en relación con los datos espaciales. ***Método:*** Se aborda el tema con un enfoque de investigación clásico mediante (i) revisiones sistemáticas para la captura de las necesidades que se presentan en diferentes áreas, y (ii) prototipado evolutivo experimental para el diseño de los procesos. ***Resultados Preliminares:*** Se han diseñado hasta el momento procesos de explotación de información para (i) el descubrimiento de patrones de co-localización, (ii) el descubrimiento de agrupaciones espaciales, y (iii) el descubrimiento de anomalías locales y regionales. ***Trabajo Futuro:*** Un proceso de explotación de información para el descubrimiento de reglas de asociación espacial se encuentra en desarrollo. Posteriormente será efectuada una iteración para la mejora de los procesos propuestos y una prueba de aplicación integral de los mismos usando datos reales.

Keywords: Explotación de Información Espacial, Minería de Datos Espaciales, Patrones de Co-Localización, Agrupamiento Espacial, Detección de Anomalías Espaciales

1 Introducción

La Explotación de Información es la disciplina encargada de obtener conocimiento implícito en grandes volúmenes de datos a fin de apoyar la toma de decisiones estratégicas de la Inteligencia de Negocio [1].

Esta disciplina se vale de los denominados "Procesos de Explotación de Información" para poder preparar, procesar y analizar grandes volúmenes de información haciendo uso de distintos algoritmos de minería de datos [2–4].

En los últimos años, debido a la llegada de nuevas tecnologías, una enorme cantidad de datos espacialmente referenciados han sido utilizados para múltiples propósitos tales como planificación urbana, logística, salud, ecología, entre otros [5, 6].

Los datos espaciales, a diferencia de los datos transaccionales tradicionales, poseen ciertas características tales como la dependencia espacial de sus atributos y los diferentes modelos de representación que hacen que los procesos de explotación de información utilizados hasta el momento [1] no se puedan aplicar de manera satisfactoria. Por otro lado, el hecho de que las entidades de datos se encuentren relacionadas con lugares determinados del espacio hace que existan relaciones más complejas que aquellas que se dan entre datos tradicionales, lo que producen variaciones semánticas en los patrones de conocimiento normalmente utilizados [7–9].

Debido a estas particularidades, resulta interesante proponer un nuevo conjunto de procesos de ingeniería para la explotación de información espacialmente referenciada que considere las particularidades inherentes a la naturaleza de los datos mencionadas anteriormente, y que especifique las transformaciones y actividades de procesamiento necesarias para la obtención de conocimiento útil para la toma de decisiones. Para esto, nos valemos de una metodología de trabajo clásica utilizando revisiones sistemáticas y prototipado evolutivo experimental para el diseño y prueba de los procesos [10, 11].

En las secciones siguientes se profundiza en los antecedentes que dan origen a esta investigación (sección 2), se enumeran los objetivos de investigación planteados (sección 3) y la metodología utilizada (sección 4), se detalla el grado de avance del trabajo realizado y las actividades pendientes de ser ejecutadas (sección 5), para finalmente presentar conclusiones (sección 6).

2 Antecedentes

En la presente sección se menciona y analiza el marco teórico y las necesidades que dan origen al trabajo de investigación presentado en este artículo. Cuestiones sobre la explotación de información y la minería de datos son abordadas en la sección 2.1, mientras que en la sección 2.2 se analizan las particularidades de los datos espacialmente referenciados en contraste con los datos transaccionales tradicionales.

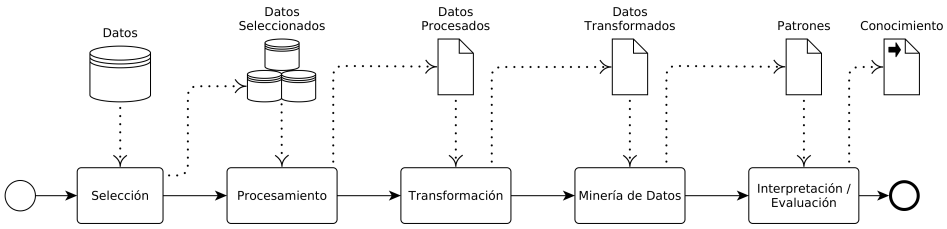

Fig. 1: Proceso de Descubrimiento de Conocimiento en Base de Datos (*KDD Process*).

2.1 Explotación de Información y Minería de Datos

La Explotación de Información es la disciplina que da a la Inteligencia de Negocio herramientas para la transformación de información en conocimiento mediante la búsqueda de patrones interesantes y de regularidades importantes en grandes masas de información [1].

Dentro de esta disciplina, se define *proceso de explotación de información* como un conjunto de tareas lógicamente relacionadas que permiten agregar valor a un conjunto de datos provistos como entrada [3, 4].

Fayyad et al. (1996) [2] propone por primera vez un proceso de explotación de información denominado proceso KDD –*Knowledge Discovery in Databases* que unifica de una manera abstracta la secuencia de pasos utilizada para la extracción de conocimiento de los datos de entrada (Fig. 1). Dentro de este proceso distintos algoritmos de minería de datos, provenientes en su mayoría del campo del Aprendizaje Automático, son susceptibles de ser utilizados de forma independiente o combinados a fin de obtener distintas clases de patrones.

Posteriormente, Britos (2008) [1] diseña un conjunto de procesos de explotación de información que se basan en el abstracto proceso KDD y que en contraste con el mismo proponen distintas combinaciones de algoritmos y técnicas de pre-procesamiento y transformación de los datos de entrada en función de los patrones que se desean obtener. Estos patrones no son arbitrarios, sino que se fundamentan en los intereses de la inteligencia de negocio [12, 13]. Entre ellos se pueden mencionar tres procesos básicos y dos procesos adicionales que surgen de la combinación de los primeros:

- Proceso para el Descubrimiento de Reglas de Comportamiento
- Proceso para el Descubrimiento de Grupos
- Proceso para la Ponderación de Interdependencia de Atributos
- Proceso para el Descubrimiento de Reglas de Pertenencia a Grupos
- Proceso para la Ponderación de Reglas de Pertenencia a Grupos

2.2 Particularidades de la Información Espacial

Los datos que se asocian con un lugar de un espacio determinado se denominan datos espacialmente referenciados o datos espaciales. Estos se encuentran

compuestos por dos clases de atributos: (i) *Atributos No-Espaciales*, que brindan información sobre el dominio del problema que se está analizando, y (ii), *Atributos Espaciales*, que asocian los valores de los atributos no-espaciales con una ubicación espacial determinada. Por ejemplo, para estudiar el comportamiento del clima de un país contamos con datos de centrales meteorológicas o puntos de control: atributos como temperatura, humedad, dirección y velocidad del viento, entre otros, corresponderían a atributos no-espaciales, mientras que la latitud, longitud y altura sobre el nivel del mar de la fuente de información corresponderían a atributos espaciales [14].

Por otro lado, existen diferentes tipos de datos para representar objetos en el espacio, dependiendo de su naturaleza. Los más básicos son: (i) los *Puntos*, que permiten representar objetos o hechos en un lugar determinado del espacio, como en el caso de las centrales meteorológicas mencionadas en el punto anterior, (ii) las *Líneas*, utilizadas para representar elementos que se extienden de manera lineal en el espacio, tales como ríos, carreteras o trayectorias de vehículos o animales, y (iii) las *Superficies*, usadas para representar áreas como parcelas de terreno, extensiones de bosques, entre otros [15].

Por último, los patrones de conocimiento obtenidos de la información espacial poseen diferencias semánticas en contraste con aquellos obtenidos a partir de información tradicional o relacional. Estas diferencias surgen a partir de relaciones más complejas entre los datos, tales como distancia y conexión entre objetos espaciales o relaciones topológicas entre los mismos. De esta forma, por ejemplo, los grupos espaciales no solo deben poseer elementos similares sino que sus elementos deben ser vecinos o conexos en el espacio, o bien las reglas de asociación no solo deben relacionar valores de atributos no-espaciales, sino que deben considerar cuestiones de posición como "A se encuentra arriba de B" o "X interseca a Y" [7, 8, 15–17]

Esta variedad de modelos de representación de los datos, la dependencia espacial de los atributos y las consecuentes variaciones semánticas en los tipos de patrones buscados, hacen que los procesos de explotación de información tradicionales y los algoritmos de minería de datos utilizados no puedan ser aplicados con resultados satisfactorios para la inteligencia de negocio [9, 18].

3 Objetivos de Investigación

Debido a las particularidades de la información espacial que hacen que los procesos de explotación de información y algoritmos de minería de datos tradicionales no puedan ser aplicados, tal como se mencionó en el apartado anterior, resulta de interés proponer un conjunto de procesos de explotación de información espacialmente referenciada útiles para la Inteligencia de Negocio.

Para esto, es necesario la identificación de los patrones de conocimiento interesantes para definir por cada uno de ellos un proceso que incluya las técnicas de preparación de datos necesarias, los algoritmos de minería de datos intervinientes y la secuencialidad de la aplicación de los mismos.

En consecuencia, se define como objetivos del trabajo de investigación:

1. Identificar patrones de conocimiento útiles para la inteligencia de negocio, a ser obtenidos a partir de datos espacialmente referenciados.
2. Diseñar un conjunto de procesos de explotación de información espacialmente referenciada, definiendo:
   - El formato de los datos de entrada, de los datos en estancias intermedias del proceso, y de los resultados del proceso.
   - La secuencia de actividades a realizar, incluyendo la preparación de los datos, el modelado y la interpretación de los resultados.
   - Los algoritmos o familia de algoritmos de minería de datos susceptibles a ser utilizados en cada actividad.
3. Validar las propuestas realizadas mediante su aplicación a datos espaciales de escenarios reales y mediante el juicio de expertos.

4 Metodología

Para construir el conocimiento necesario para el cumplimiento de los objetivos de investigación propuestos en la sección 3.1 del presente artículo, se utiliza un enfoque de investigación clásico [10] haciendo énfasis en la producción de tecnologías [11].

Se realiza una exploración documental mediante el método de revisiones sistemáticas [19, 20] para la determinación de las necesidades de la inteligencia de negocio, esto es, cuáles son los patrones de conocimiento de interés asociados a los datos espaciales. Por cada uno de dichos patrones identificados, se realiza un relevamiento de los algoritmos y técnicas utilizadas comúnmente para la preparación, el pre-procesado y el minado de los datos espaciales.

Posteriormente, por cada necesidad planteada, se utiliza el método de prototipado evolutivo experimental [21] para el diseño de los procesos de explotación de información. En este paso se seleccionan del relevamiento llevado a cabo en el paso anterior los algoritmos y técnicas mencionados en el estado del arte factibles de ser utilizados, se realizan modificaciones a los mismos en caso de ser necesarios, se especifica la secuencialidad de las actividades, se definen cuáles son los atributos de los datos que intervienen en el proceso y de qué forma lo hacen, y se realizan pruebas de funcionamiento mediante el uso de datos tanto simulados como reales.

Al finalizar cada una de las etapas, se realizará una prueba integral de todos los procesos frente a escenarios reales, contrastando los resultados obtenidos con la opinión de expertos.

5 Realización de la Investigación

En esta sección se detallan las distintas actividades llevadas a cabo (sección 5.1) y las actividades pendientes de ejecución (sección 5.2) para el cumplimiento de los objetivos especificados anteriormente siguiendo las formas metodológicas mencionadas.

5.1 Actividades Realizadas

La investigación comenzó formalmente en el mes de febrero del año 2016. Desde ese momento hasta la actualidad se han diseñado tres procesos de explotación de información en el marco de este trabajo académico y mediante la metodología mencionada anteriormente: (i) Un proceso para el descubrimiento de patrones de co-localización, (ii) un proceso para la caracterización de regiones espaciales, y (iii) un proceso para el descubrimiento de anomalías espaciales.

De esta forma, el primer proceso mencionado utiliza reglas de clasificación para poder detectar patrones de co-localización dada una clase de objeto espacial de referencia tras la generación de datos transaccionales usando cliques máximos; el segundo proceso diseñado permite la generación de regiones espaciales utilizando algoritmos de agrupamiento espacial y una descripción de cada región detectada utilizando árboles de decisión sobre los atributos no espaciales de los datos; por último, el tercer proceso desarrollado permite una regionalización automática del conjunto de datos mediante algoritmos de agrupamiento espacial para una posterior búsqueda de anomalías en cada uno de los grupos generados y una posterior detección del grado de anormalidad de cada uno de las regiones halladas a fin de determinar si son anormales en su vecindario.

Estos diseños han dado lugar a dos publicaciones en el Congreso Argentino de Ciencias de la Computación (CACIC) [22, 23], dos publicaciones en *International Conference on Industrial, Engineering & Other Applications of Applied Intelligent Systems* (IEA-AIE) [24] (uno pendiente de publicación), y una publicación en *International Conference on Software Engineering and Knowledge Engineering* (SEKE) [25].

5.2 Actividades Futuras

En la actualidad, un proceso de explotación de información para la detección de asociaciones espaciales se encuentra en proceso de ser diseñado.

Posteriormente se planea la realización y publicación de un artículo en un congreso de alcance internacional para la comunicación de los resultados que se obtendrán tras el diseño del proceso mencionado y un artículo para una revista indizada de alcance internacional que integre toda la producción científica de este trabajo de investigación.

Por último, para finalizar el trabajo relacionado con la tesis doctoral, se planea validar los procesos producto de este trabajo de investigación utilizando datos de escenarios reales variados contrastando los resultados con la opinión de expertos en dichos campos.

Continuamente y en función de los nuevos avances en materia de algoritmia para minería de datos espaciales, se evalúa la mejora de los procesos diseñados hasta el momento.

6 Conclusiones

El trabajo de investigación detallado en el presente artículo contribuye aportando un conjunto de procesos de ingeniería para la explotación de información

espacialmente referenciada. Estos procesos detallan la forma en la cual esta información particular debe ser tratada y procesada a fin de poder descubrir, hasta el momento, (i) reglas de asociación espaciales, (ii) patrones de co-localización, (iii) regiones espaciales, y (iv) anomalías espaciales, útiles para la Inteligencia de Negocio para la toma de decisiones estratégicas.

Para esto, por cada uno de ellos se especifican: (i) las fuentes y formatos de los datos de entrada y la forma de integrarlos, (ii) las transformaciones de los mismos, (iii) los algoritmos de minería de datos a ser aplicados, (iv) las salidas del proceso, (v) la forma en la cual los resultados deben ser interpretados, y (vi) el orden de ejecución de las tareas.

Cada uno de estos procesos estarán validados mediante su aplicación ante escenarios tanto simulados como reales y mediante el juicio de expertos.

Agradecimientos

Esta investigación ha sido parcialmente financiada por el Programa de Becas Doctorales para el Fortalecimiento de Áreas I+D+i (2016-2020) de la Universidad Tecnológica Nacional, por el Proyecto de Investigación 80020160400001LA de la Universidad Nacional de Lanús, y por PIO CONICET-UNLa 22420160100032CO del Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET), Argentina. Se agradece además a los atentos revisores de este trabajo por su mirada crítica y por sus valiosos comentarios. En memoria del Prof. Dr. Ramón García-Martínez.

Referencias

1. Britos, P. V. (2008). Procesos de explotación de información basados en sistemas inteligentes (Doctoral dissertation, Facultad de Informática).
2. Fayyad, U. M., Piatetsky-Shapiro, G., & Smyth, P. (1996, August). Knowledge Discovery and Data Mining: Towards a Unifying Framework. In KDD (Vol. 96, pp. 82-88).
3. García Martínez, R. (1997). Sistemas Autónomos. Aprendizaje Automático. Editorial Nueva Librería (p. 2004). ISBN 950-9088-84-6. García Martínez, R. y Britos.
4. García Martínez, R., Servente, M., & Pasquini, D. (2003). Sistemas Inteligentes. Editorial Nueva Librería. Buenos Aires. ISBN 987-1104-05-7.
5. Mennis, J., & Guo, D. (2009). Spatial data mining and geographic knowledge discovery—An introduction. Computers, Environment and Urban Systems, 33(6), 403-408.
6. Mazimpaka, J. D., & Timpf, S. (2016). Trajectory data mining: A review of methods and applications. Journal of Spatial Information Science, 2016(13), 61-99.
7. Yang, H., & Parthasarathy, S. (2006). Mining spatial and spatio-temporal patterns in scientific data. In Data Engineering Workshops, 2006. Proceedings. 22nd International Conference on (pp. x146-x146). IEEE.
8. Leung Y. (2010) Introduction. In: Knowledge Discovery in Spatial Data. Advances in Spatial Science (The Regional Science Series). Springer, Berlin, Heidelberg. Online ISBN: 978-3-642-02664-5. DOI: 10.1007/978-3-642-02664-5

9. Goudarzi, A. H., & Ghadiri, N. (2017). A hybrid spatial data mining approach based on fuzzy topological relations and MOSES evolutionary algorithm. arXiv:1704.06621.
10. Creswell, J. W. (2002). Educational research: Planning, conducting, and evaluating quantitative (pp. 146-166). Upper Saddle River, NJ: Prentice Hall.
11. Sabato, J. A., & McKenzie, M. (1982). La producción de tecnología: autonoma o transnacional. Medellín: Nueva Imagen.
12. García-Martínez, R., Britos, P., Pesado, P., Bertone, R., Pollo-Cattaneo, F., Rodríguez, D., ... & Vanrell, J. (2011). Towards an information mining engineering. Software Engineering, Methods, Modeling and Teaching, 83-99.
13. García-Martínez, R., Britos, P., & Rodríguez, D. (2013, June). Information mining processes based on intelligent systems. In International Conference on Industrial, Engineering and Other Applications of Applied Intelligent Systems (pp. 402-410). Springer, Berlin, Heidelberg.
14. Koperski, K., Adhikary, J., & Han, J. (1996, June). Spatial data mining: progress and challenges survey paper. In Proc. ACM SIGMOD Workshop on Research Issues on Data Mining and Knowledge Discovery, Montreal, Canada (pp. 1-10).
15. Malerba, D. (2008). A relational perspective on spatial data mining. International Journal of Data Mining, Modelling and Management, 1(1), 103-118.
16. Malerba, D., & Lisi, F. (2001). Discovering associations between spatial objects: An ILP application. Inductive logic programming, 156-163.
17. Liu, Q., Deng, M., Shi, Y., & Wang, J. (2012). A density-based spatial clustering algorithm considering both spatial proximity and attribute similarity. Computers & Geosciences, 46, 296-309.
18. Kataria, P., & Rupal, N. (2012). Mining Spatial Data & Enhancing Classification Using Bio-Inspired Approaches. International Journal of Science and Research (IJSR), 3(2), 1473-1479.
19. Kitchenham, B. (2004). Procedures for performing systematic reviews. Keele, UK, Keele University, 33(2004), 1-26.
20. Kitchenham, B., Brereton, O. P., Budgen, D., Turner, M., Bailey, J., & Linkman, S. (2009). Systematic literature reviews in software engineering–a systematic literature review. Information and software technology, 51(1), 7-15.
21. Basili, V. R. (1993). The experimental paradigm in software engineering. In Experimental Software Engineering Issues: Critical Assessment and Future Directions (pp. 1-12). Springer, Berlin, Heidelberg.
22. Rottoli, G., Merlino, H., & García Martínez, R. (2016a). Proceso de descubrimiento de patrones de co-localización alrededor de tipos de eventos de referencia. In XXII Congreso Argentino de Ciencias de la Computación (CACIC 2016).
23. Rottoli, G., Merlino, H., & García Martínez, R. (2016b). Proceso de descubrimiento de reglas de caracterización de grupos espacialmente referenciados. In XXII Congreso Argentino de Ciencias de la Computación (CACIC 2016)..
24. Rottoli, G. D., Merlino, H., & García-Martinez, R. (2017a). Co-location Rules Discovery Process Focused on Reference Spatial Features Using Decision Tree Learning. In International Conference on Industrial, Engineering and Other Applications of Applied Intelligent Systems (pp. 221-226). Springer, Cham. DOI: 10.1007/978-3-319-60042-0_25
25. Rottoli, G. D., Merlino, H., & García-Martinez, R. (2017b). Knowledge Discovery Process for Description of Spatially Referenced Clusters. In International Conference on Software Engineering & Knowledge Engineering. (pp.410–415) Ed. USA KSI Research Inc. and Knowledge Systems Institute. DOI: 10.18293/SEKE2017-013