Formulación de Procesos para una Ingeniería de Explotación de Información Espacial

Giovanni Daián Rottoli

Doctorado en Ciencias Informáticas - Universidad Nacional de La Plata - Argentina

Grupo de Investigación en Sistemas de Información (GISI) - Universidad Nacional de Lanús - Argentina

Tabla de Contenidos

1. Introducción
2. Desarrollo de la Investigación
3. Resultados
4. Conclusiones y Trabajos Futuros

Introducción

Definiciones Básicas

Explotación de Información

Es una disciplina que brinda a la Inteligencia de Negocio herramientas para obtener conocimiento a partir de información disponible en grandes volúmenes de datos.

Procesos de Explotación de Información

Tareas relacionadas lógicamente para agregar valor a un conjunto de datos provistos de entrada.

Minería de Datos

Técnicas y algoritmos de inteligencia artificial y aprendizaje automático para la búsqueda de patrones y regularidades en conjuntos de datos.

Proceso KDD

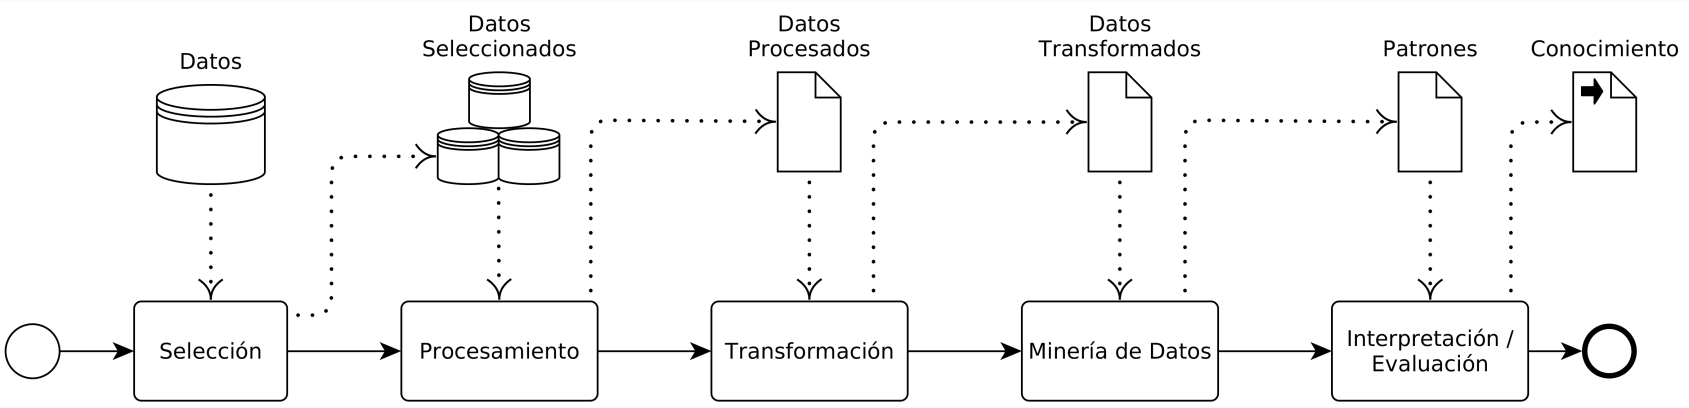

(Fayyad et al., 1996)

Procesos de Explotación de Información

- Proceso de Descubrimiento de Reglas de Comportamiento
- Proceso de Descubrimiento de Grupos
- Proceso de Ponderación de Interdependencia de Atributos
- Proceso de Descubrimiento de Reglas de Pertenencia a Grupos
- Proceso de Ponderación de Reglas de Pertenencia a Grupos

(García-Martínez et al., 2013)

Datos Espaciales

Estructura

$$d = [x_1, x_2, \cdots, x_n, v_1, v_2, \cdots, v_m]$$

$$x_i : AtributosEspaciales$$

$$v_j : AtributosNoEspaciales$$

Tipos

Puntos

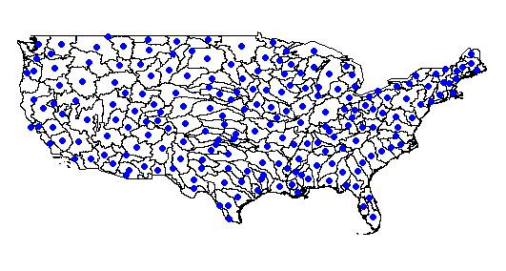

Líneas

Áreas

Datos Espaciales

Relaciones

- De Distancia
- Direccionales
- Topológicas
- Mixtas

Propiedades

- Autocorrelación Espacial
- Heterogeneidad Espacial
- Diferencias en los Patrones

Problema

Debido a las particularidades que presenta la información espacial, los procesos de explotación de información tradicionales no pueden ser aplicados.

Los patrones de conocimiento obtenidos no resultan útiles para la inteligencia de negocio.

Se requieren actividades diferentes de integración, preparación, transformación, modelado e interpretación.

Preguntas de Investigación

1. ¿Es posible diseñar un conjunto de procesos de explotación de información espacial que incluya las entradas y salidas del mismo y las actividades de preparación, modelado e interpretación de datos para obtener patrones de conocimiento útiles para la Inteligencia de Negocio en relación a las características particulares de esta clase de información?
2. En caso afirmativo
   - 2.1 ¿ Cuáles son las estrategias necesarias de preparación y transformación de los datos en cada caso?
   - 2.2 ¿ Cuáles son los algoritmos de minería de datos susceptibles a ser utilizados en cada proceso?

Desarrollo de la Investigación

Objetivos

1. Identificar patrones de conocimiento útiles para la inteligencia de negocio, a ser obtenidos a partir de datos espacialmente referenciados.
2. Diseñar un conjunto de procesos de explotación de información espacial, definiendo:
   - 2.1 El formato de los datos de entrada, de los datos en instancias intermedias del proceso, y de los resultados del proceso.
   - 2.2 La secuencia de actividades a realizar, incluyendo la preparación de los datos, el modelado y la interpretación de los resultados.
   - 2.3 Los algoritmos o familia de algoritmos de minería de datos susceptibles a ser utilizados en cada actividad.
3. Validar las propuestas realizadas mediante su aplicación a datos espaciales de escenarios reales y mediante el juicio de expertos.

Materiales y Métodos

- Enfoque clásico con énfasis en producción de tecnologías
- Revisiones Sistemáticas
- Prototipado Evolutivo Experimental
- Pruebas de validación ante escenarios reales y juicio de expertos

Resultados

Resultados Parciales

Se han diseñado hasta el momento 3 Procesos de Explotación de Información Espacial:

- Proceso para el Descubrimiento de Patrones de Co-Localización
- Proceso para la Caracterización de Regiones Espaciales
- Proceso para el Descubrimiento de Anomalías Espaciales

Patrones de Co-Localización

Búsqueda de tipos de objetos espaciales que usualmente se encuentran próximos en el espacio.

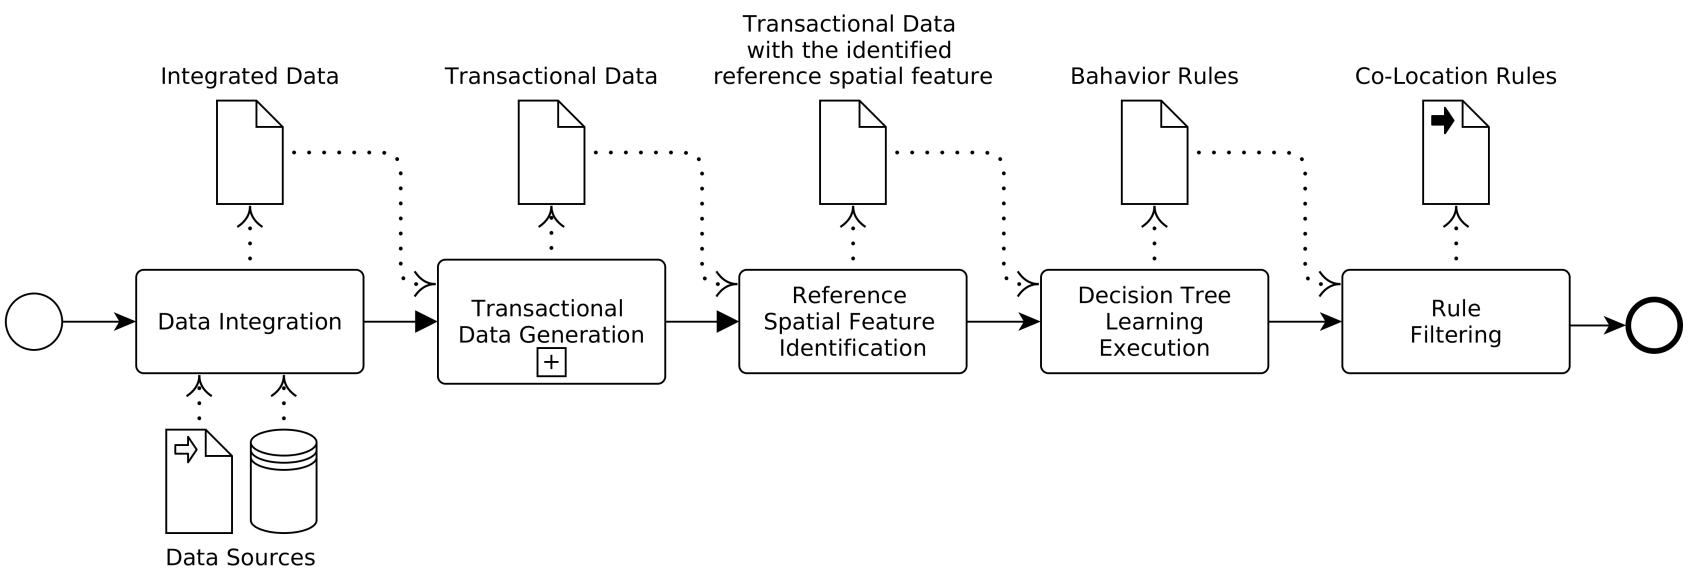

El proceso permite encontrar co-localizaciones completas y correctas alrededor de tipos de eventos de referencia utilizando cliques máximos para la transaccionalización de los datos.

Caracterización de Regiones Espaciales

Búsqueda de regularidades en regiones espaciales automáticamente generadas.

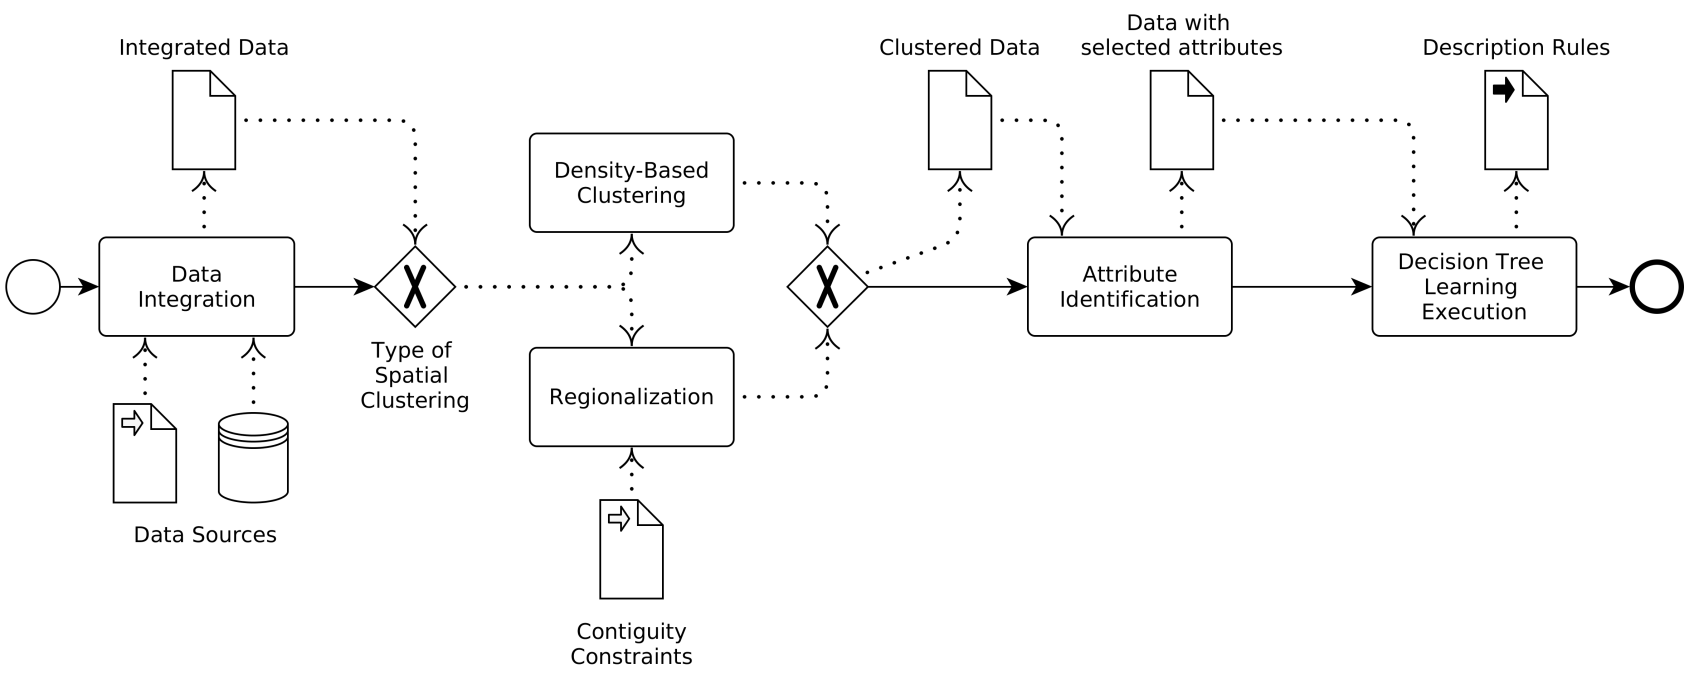

El proceso permite optar por una estrategia de clustering basada en densidad y una basada en regionalización, y la posterior descripción de los grupos en función de los atributos no-espaciales.

Anomalías espaciales

Búsqueda de datos anormales en regiones y regiones anormales.

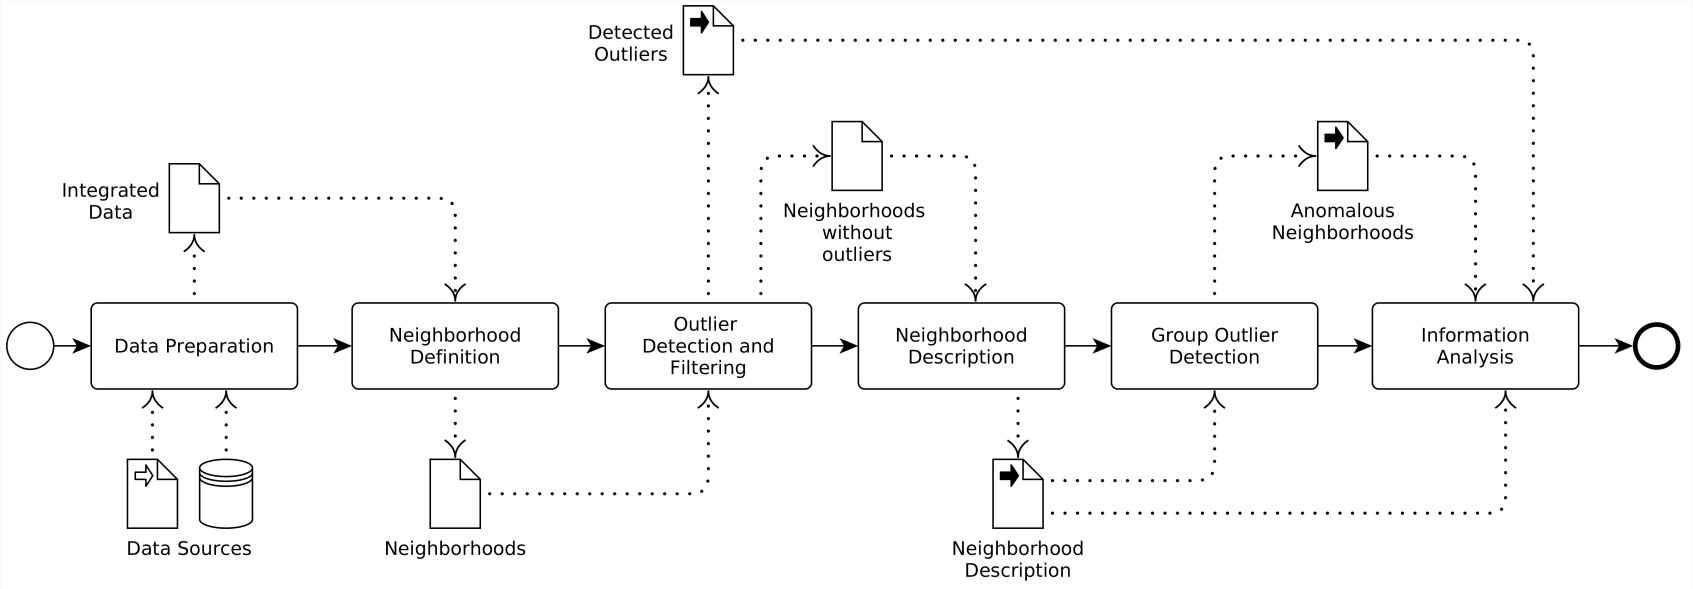

El proceso permite encontrar anomalías locales y regiones anómalas, y provee información para la posterior descripción de dichas anomalías en función de los atributos no-espaciales de los datos.

Conclusiones y Trabajos Futuros

Conclusiones

- La naturaleza de los datos espaciales hace que los procesos de explotación de información tradicionales no se puedan aplicar.
- La tesis doctoral llevada a cabo busca el diseño de nuevos procesos que salven estas diferencias.
- Hasta el momento se han diseñado y probado tres procesos de explotación de información espacial que han sido probados con resultados satisfactorios

Trabajos Futuros

- Dentro del marco de la tesis doctoral:
  - Un cuarto y último proceso para la búsqueda de asociaciones espaciales se encuentra en desarrollo.
  - Es necesaria una evaluación final de todos los procesos de explotación de información dirigida por las mejoras en el campo para una iteración de ajuste final.
- Queda pendiente una evaluación de cuáles son los algoritmos más convenientes para ser aplicados dentro de cada proceso en relación a las particularidades de los datos y del dominio del problema.

Cuestiones pendientes

- ¿ Cuáles consideran las mejores estrategias para evaluar los procesos de explotación de información?
- ¿ Consideran que se deben proponer algoritmos de minería de datos más específicos en cada proceso, aún en detrimento de la flexibilidad del mismo?
- ¿ Consideran útil la propuesta de estrategias de elección de algoritmos en función de las características del dominio del problema ?